

# Relatório da Variação Paramétrica - I

Alunos:  
André Luiz Pereira da Silva ([alps2@cin.ufpe.br](mailto:alps2@cin.ufpe.br))  
Victoria Célia César Ferreira ([vccef@cin.ufpe.br](mailto:vccef@cin.ufpe.br))

## Função de Otimização

A ferramenta gridsearch será usada para determinar a melhor combinação de parâmetros para cada modelo.

Uma função search é definida, que recebe uma instância de modelo a ser "variado" e um dicionário de parâmetros e suas variações.

```
def search(model, model_parameters):  
    """  
    model_pipeline = Pipeline([  
        ('clf', model)  
    ])  
  
    grid_search = GridSearchCV(  
        model_pipeline,  
        model_parameters,  
        n_jobs=N_JOBS,  
        cv=FOLDS,  
        verbose=1  
    )  
  
    grid_search.fit(X_train, y_train.values.ravel())  
  
    print(f"Best score after optimization: {grid_search.best_score}")  
    print("Best params:")  
    for key, value in grid_search.best_params_.items():  
        print(f"{key}: {value}")  
  
    return grid_search
```

## Variando K-NN

Parâmetros e ranges escolhidos para a variação:

- n\_neighbors[4,10]: número de vizinhos.
- weights["uniform", "distance"]: função de peso usada para a previsão. No uniform todos os pontos tem o mesmo peso e no distance pontos mais próximos terão mais influência.
- algorithm["auto", "ball\_tree", "kd\_tree", "brute"]: algoritmo para calcular os vizinhos mais próximos.
- leaf\_size[20,40]: parâmetro usado no BallTree ou KDTree. O default é 30, então decidimos um range intermediário.
- metric ["cityblock","cosine","euclidean","haversine","nan\_euclidean"]: métrica usada para calcular a distância.
- P[1,3]: parâmetro usado na métrica de Minkowski. Se p = 1, vai usar a manhattan\_distance e se p=2 a euclidean\_distance. Qualquer outro valor vai usar a minkowski\_distance.

Antes de usar o metric:

```
Fitting 10 folds for each of 1920 candidates, totalling 19200 fits  
Best score after optimization: 0.9988826815642458  
Best params:  
clf__algorithm: auto  
clf__leaf_size: 20  
clf__n_neighbors: 4  
clf__p: 1  
clf__weights: distance
```

Após usar o metric:

```
Best score after optimization: 0.9996275605214151  
Best params:  
clf__algorithm: auto  
clf__leaf_size: 20  
clf__metric: cityblock  
clf__n_neighbors: 8  
clf__p: 1  
clf__weights: distance
```

## Variando Decision Tree

Parâmetros e ranges escolhidos para a variação:

- criterion ["gini", "entropy", "log\_loss"]: Algoritmo para medição de qualidade de divisão de nós. Servem para determinar quais as melhores features para estarem mais perto do topo da árvore (ou seja, que apresentem maior ganho de informação).
- splitter["best", "random"]: como os dados vão ser divididos a cada nó. Quando o splitter ocorre os dados são divididos em 2 ou mais subconjuntos e 1 nó para cada subconjunto é criado. A divisão dos dados procura melhor separar as diferentes classes.
- max\_features [0.2,0.4,0.6,0.8, None, "sqrt", "log2"]: máximo número de features/atributos considerados para o melhor overfitting possível a cada nó da árvore. Usar muitas features resulta em overfitting e usar poucas em underfitting. Se não especificado o número máximo de features, o modelo irá treinar com todas as features.
- max\_depth[3, 50]: Máxima profundidade da árvore. Na construção de uma árvore de decisão o algoritmo recursivamente divide os dados em subconjuntos baseado nas features/atributos, até parar. Uma das formas de fazer o algoritmo parar é setando um valor máximo da profundidade da árvore, que é o max\_depth. Se a árvore for muito profunda resulta em overfitting, se for pouco profunda resulta em underfitting.

```
Fitting 10 folds for each of 1974 candidates, totalling 19740 fits  
Best score after optimization: 0.9990689013035382  
Best params:  
clf__criterion: gini  
clf__max_depth: 31  
clf__max_features: None  
clf__splitter: best
```

## Variando SVM

Parâmetros e ranges escolhidos para a variação:

- kernel["linear", "poly", "rbf", "sigmoid"]: O kernel é uma função matemática para transformar dos dados do input do seu espaço de features original em uma espaço de maior dimensão, para facilitar a separação de classes usando um classificador linear. A função de kernel recebe 2 vetores como input e retorna um valor escalar que mede a distância entre eles no espaço transformado. Essa medida de semelhança/distância é usada para encontrar o hiperplano que separa as classes diferentes no espaço transformado, com a maior distância possível entre os 2 pontos mais próximos de cada classe diferente.  
Linear: o espaço original;  
Polinomial: uma função polinomial sobre os dados de entradas;  
Gaussiana: uma função gaussiana é usada para medir a similaridade entre os vetores de entrada;  
Sigmoid: uma função sigmóide sobre os dados de entradas.
- gamma["scale", "auto"]: o kernel coefficient (coeficiente do kernel). Controla a forma e largura da função de kernel. Define o range de influência de 1 único exemplo de treinamento na fronteira de decisão. Se o gamma é menor, a fronteira é mais simples e a influência de cada exemplo do treinamento é maior. Se gamma é maior, a fronteira de decisão é mais complexa e a influência de cada exemplo de treinamento é menor.
- C[0.1,0.2,0.3,0.4,0.5,0.6,0.7,0.8,0.9,1.0]: o regularization parameter (parâmetro de regularização). O C controla o trade-off entre maximizar a margem e minimizar o erro de classificação. O C determina a penalidade por classificar de forma errada os exemplos de treinamento. Se C é pequeno, a penalidade é menor e a margem maior, se C é maior a penalidade é maior e a margem menor. Um C muito grande resulta em overfitting, um C muito pequeno resulta em underfitting. O valor de C é determinado com o valor de outros hiperparâmetros como o gamma, para encontrar a combinação que leve a melhor performance. O C foi entre 0.1 e 1.0 pois foram vistos exemplos de outros modelos sendo treinados e esses eram os valores vistos.
- range [1,4]: grau da função polinomial

```
Fitting 10 folds for each of 240 candidates, totalling 2400 fits  
Best score after optimization: 0.9936681814391729  
Best params:  
clf__C: 1.0  
clf__degree: 1  
clf__gamma: auto  
clf__kernel: rbf
```

## Variando Random Forest

Parâmetros e ranges escolhidos para a variação:

- n\_estimators [50:150]: Número de árvores de decisão presentes na floresta.
- criterion ["gini", "entropy", "log\_loss"]: Algoritmo para medição de qualidade de divisão de nós. Servem para determinar quais as melhores features para estarem mais perto do topo da árvore (ou seja, que apresentem maior ganho de informação).
- max\_depth [3:50]: Profundidade máxima da árvore. O próprio SKLearn recomenda 3 como mínimo. O máximo depende muito das situações, mas via de regra, uma árvore mais profunda representa um classificador com risco de overfitting. Manter uma profundidade balanceada pode garantir um modelo mais genérico que consegue lidar com registros novos (diferentes dos que foram usados para o treino) sem muitos problemas.
- max\_features ["sqrt", "log2", None]: Número de atributos a serem considerados na hora de dividir.

```
Fitting 10 folds for each of 49350 candidates, totalling 493500 fits  
Best score after optimization: 0.9986964618249534  
Best params:  
clf__criterion: entropy  
clf__max_depth: 8  
clf__max_features: 0.8  
clf__n_estimators: 106
```

## Variando Rede Neural MLP

Parâmetros e ranges escolhidos para a variação:

- hidden\_layer\_sizes [(100,), (50, 50,), (33, 33, 34,), (25, 25, 25, 25,)]: Quantidade de camadas internas do perceptron (e o número de neurons em cada uma)
- Activation ["identity", "logistic", "tanh", "relu"]: Função de ativação para os neurons.
- Solver ["lbfgs", "sgd"]: De acordo com o sklearn, o solver "adam" funciona melhor com datasets maiores (na casa das dezenas de milhares). Como nosso dataset tem uma escala menor, seu uso não é recomendado, pois as alternativas convergem mais rapidamente e performam melhor.

```
Best score after optimization: 0.9983240223463687  
Best params:  
clf__activation: logistic  
clf__hidden_layer_sizes: (100,)  
clf__solver: lbfgs  
/home/alps2/.local/lib/python3.10/site-packages/sk  
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.
```

## Variando Comitê de redes neurais Artificiais

Como o algoritmo Bagging é um ensemble e pode receber vários classificadores, decidimos instanciar o MLP com o resultado de sua otimização, para garantir maior qualidade do comitê.

Parâmetros e ranges escolhidos para a variação:

- n\_estimators [5:15]: Número de classificadores presentes no comitê.
- max\_samples [0.2:1]: Número de registros a serem extraídos de X na hora de treinar cada classificador do comitê.
- max\_features [0.2:1]: Número de atributos a serem considerados na hora de treinar cada classificador do comitê.

```
Best score after optimization: 0.9979515828677838  
Best params:  
clf__max_features: 0.8  
clf__max_samples: 0.8  
clf__n_estimators: 14  
/home/alps2/.local/lib/python3.10/site-packages/sk  
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.
```

## Variando Comitê Heterogêneo

Como o algoritmo VotingClassifier é um ensemble e pode receber vários classificadores diferentes, decidimos instanciá-los já com os melhores parâmetros provenientes de suas otimizações. Os classificadores escolhidos para o VotingClassifier foram:

- MLP
- Random Forest
- SVM
- KNN

Parâmetros e ranges escolhidos para a variação:

- voting ["hard", "soft"]: Regra para definir vencedor da votação (maioria simples com hard, probabilidade de classes com soft).
- weights [None, [2.5, 2, 1.5, 1]]: pesos atribuídos para cada classificador. No caso de None, o peso é uniforme. Caso contrário, os pesos passados são atribuídos. Declaramos os classificadores em ordem do mais preciso para o menos preciso, garantindo que os melhores classificadores influenciam mais na decisão.

```
Best score after optimization: 0.9988826815642458  
Best params:  
clf__voting: hard  
clf__weights: None
```